

Статистический подход к анализу временных рядов.

Модели временных рядов

Часто вводится аддитивная модель ВР

$$y(t) = \text{trend}(t) + \text{seasonal}(t) + \text{noise}(t).$$

где $\text{trend}(t)$ - тренд ВР, $\text{seasonal}(t)$ – сезонность ВР, $\text{noise}(t)$ – остаточная часть ВР

Иногда также разделяют тренд на уровень, тренд и цикличность:

$$y(t) = a_0 + \text{trend}'(t) + \text{cyclic}(t) + \text{seasonal}(t) + \text{noise}(t).$$

где a_0 - постоянная составляющая, $\text{cyclic}(t)$ – цикличность ВР, $\text{trend}'(t)$ - остальной тренд
напр. если выделяют уровень экономики a_0 ,

- цикличность кризисов,
- **тренд** экономики
- **сезонные факторы** (год, неделя и тд) -

Особенности модели временных рядов

- Как правило тренд и сезонность объяснить частично можно (это структура BP)
 - можно разложить BP на тренд и сезонность известного типа. То что останется – мы считаем шумом (случайные колебания).
- Шум создает неопределенность или смещение в результатах предсказаний
- Данные с шумом можно описать статистически (ввести статистические гипотезы о данных)
- При статистическом анализе BP введем стат. Характеристики BP

Пример 1

Прогнозирование спроса в баре:

Структура:

Повышенные продажи по пятницам (holidays effect).

Рост выручки летом (сезонность).

Влияние футбольных матчей (календарные эффекты).

Шум:


Изменение числа посетителей по пятницам (или другим дням)

Остаточная часть может содержать информацию, необъясненную моделью!

Вопрос аудитории:

"Можно ли полностью устранить шум? Что произойдет, если игнорировать его при планировании запасов?"

Пример 2 Electricity Transformer Temperature



Белый Гауссов шум




В идеале остаточная часть не содержит информации, равномерно распределена и все ее значения независимы друг от друга (identical independent distribution - i.i.d) – такая остаточная часть называется Белый Гауссов Шум (White Gaussian Noises).

- Обратите внимание, что WGN имеет так называемое нормальное распределение с нулевым средним.

$$f(wgn) = \frac{1}{std(wgn)\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{wgn}{std(wgn)}\right)^2},$$

- где $f(wgn)$ распределение.

Пример wgn - это когда вы включаете антенну с телевизора и увидеть так называемый «снег»



Статистические свойства ВР

- Если временной ряд не является белым гауссовым шумом и не нарушает принципов оцифровки ВР, то каждый его отсчет зависит от предыдущих
- Введем для такого ряда статистические свойства:
 - **Автокорреляция (АКФ)** – зависимость каждого значения ВР от его предыдущих значений (бывает полная и частичная АКФ).
 - **Стационарность** – свойства сохранности основных статистических значений независимо от момента взятия выборки ВР (сильная и слабая стационарность)
 - Могут быть и другие статистические показатели, например:
 - **Гомоскедастичность** – свойство ВР сохранять дисперсию во времени. **Гетероскедастичность** (Heteroskedasticity) – волатильность ВР
 - **Окрашенность шума** – наличие в шуме автокорреляционных свойств
 - **Долговременная связанность** (показатель Херста) – долговременная зависимость ВР от своих лагов (напр. Тренд)
 - **Нелинейность ВР** – компоненты связаны сложными зависимостями (напр. Модуляция)
 - **Структурные разрывы** (ряд с новизной или точками перегиба)

Автокорреляция ВР


- Получим численную оценку степени влияния значения y_t на значение $y_{t+\tau}$ (оценки корреляции) в виде коэффициента корреляции Пирсона для ВР с самим собой со сдвигом на τ – автокорреляцию ВР (АКФ).

$$cor(\tau) = \frac{1}{N} \frac{\sum_{i=0}^{N-1} (y_t - ev)(y_{t+\tau} - ev)}{var(y)}$$

Где среднее значений (или ожидаемое значение), $ev = \frac{1}{N} \sum_{i=0}^{N-1} y_i$, теор. формула $ev = \sum_{i=0}^{N-1} p(y_i)y_i$

где y - выборки размера N , $p(y)$ – распределение значений величины


$var = \frac{1}{N} \sum_{i=0}^{N-1} (y_i - ev)^2$; $std = \sqrt{var}$, где var - дисперсия; std - стандартное отклонение



Например, если мы хотим оценить степень влияния сегодняшней температуры на завтрашнюю, то посчитаем коэффициент корреляции исходного ряда и его же, сдвинутым на 1 день.

<https://otexts.com/fpp3/acf.html>

Australian antidiabetic drug sales



Замечания к автокорреляции





- $cor(\tau) > 0$ – положительная корреляция, то есть чем *больше* было значение вчера, тем оно будет *больше* сегодня;
- $cor(\tau) < 0$ – отрицательная корреляция, то есть чем *больше* было значение вчера, тем оно будет *меньше* сегодня;
- $|cor(\tau)| \leq 1$; $cor(\tau) = 1$ означает строгую линейную зависимость.
- $|cor(\tau)| \leq 0.05$ (0.01) может колебаться из-за шума
- Значимые корреляции проверяются отдельными стат. тестами

$cor(\tau) = 0$ – отсутствие автокорреляции, при этом значения могут быть зависимыми;

Независимость $\Rightarrow$ некоррелированность

$\Leftarrow$



—



Четыре различных набора данных, коэффициент корреляции на которых равен 0.81

Пример дорожно-транспортных происшествий за 14 лет с дискретностью 1 месяц,



- Видна годовая сезонность.
- На графике АКФ видны максимумы на 12 лагах
- r_{12} является локальным максимумом, что означает высокую положительную корреляцию значения ряда за текущий месяц с аналогичным значением год назад.
- Закрашенная область визуализирует границу незначимой автокорреляции, то есть тех значений автокорреляции, для которых не выявлена статистически значимое отличие от 0 (иначе говоря, доверительный интервал пересекает 0).
- Значимые лаги: 1, 2, 6, 12, 24 – именно эти лаги связаны и на них имеет смысл строить прогноз (0 лаг не считается!)



Корреляция

Пример ACF. Синяя линия показывает уверенность согласно тексту Бокса-Льюнга по уровню p -value 0,05(корреляции ниже – случайные).



ВР не имеет тренда и сезонности, каждое следующее значение связано с 3мя предыдущими



<https://library.altspu.ru/dc/pdf/kizbikenov.pdf>

Замечания

- **ВР имеет тренд** → АКФ для небольших лагов, как правило, большие и положительные, поскольку наблюдения, близкие по времени, также близки по значению.
 - Таким образом, АСФ трендового временного ряда, как правило, имеет положительные значения, которые медленно уменьшаются по мере увеличения лагов.
- **Если данные сезонные**, автокорреляции будут больше для сезонных лагов (кратных сезонному периоду), чем для других лагов.
- **Данные являются как трендовыми, так и сезонными**, будет иметь место комбинация этих эффектов (см. ниже).





Частичная автокорреляция

- Фактически АКФ $cor(\tau)$ показывает связанность ВР и всех сдвинутых его копий до значения τ .
 - Иногда это мешает понять связанность конкретно с лагом τ . Для компенсации этого используют **Частичную АКФ (ЧАКФ, PACF)**:

$$PACF(k) = cor(y_{n+k} - y_{n+k}^{n+k-1}, y_n - y_n^{n-1});$$

- где y_n^{n-1} – значение, предсказанное как результат линейной регрессии по лагам $y_{n-1}, y_{n-2}, \dots, y_{n-k}$
- Частичная корреляция снимает (устраняет) линейную зависимость от промежуточных лагов
Например, если мы регрессируем переменную Y по переменным X_1, X_2 и X_3 , частичная корреляция между Y и X_3 - это степень корреляции между Y и X_3 , которая не объясняется их общими корреляциями с X_1 и X_2 .



На ЧАКФ видны сезонные колебания

Частичная автокорреляция

пример: В промышленности: отделение сигнала поломки оборудования по вибрации от регулярных вибраций


в гидрологии PACF отделяет влияние непосредственных предшествующих наблюдений от сезонных эффектов

в машинном обучении: формирование признаков только из нужных лагов без избыточности

Анализ стационарности


Нестационарный ряд - временной ряд считается нестационарным, если некоторые из его статистических свойств меняются с течением времени.

Другими словами, ВР имеет переменную среднее времени, дисперсию или другие статистические характеристики.




Стационарность ВР

- **В узком смысле**, при сдвиге в любой момент времени ВР на одном и том же размер. Выборки имеет одно и тоже распределение
 - если для любых $t_1, \dots, t_n$, и τ вектор $(y_{t_1+\tau}, \dots, y_{t_n+\tau})$ совпадает по распределению с $(y_{t_1}, \dots, y_{t_n})$
- **В широком смысле**: если статистические свойства ВР не меняются с течением времени.
- Другими словами, ряд имеет постоянное среднее значение и дисперсию, а ковариация зависит только от разницы индексов лагов.
 - указанные статистические характеристики не должны быть бесконечными.
 - $E y_t^2 < +\infty$ для любого t . $E y_t$ не зависит от t , то есть в среднем значение временного ряда постоянно.
 $\text{Cov}(t) = \text{Cov}(t+\tau)$, то есть значение автокорреляции зависит только от длины отрезка времени между двумя значениями



Анализ нестационарности

Если ВР имеет тренд, выраженную сезонность или переменную дисперсию (гетеросекдстичность), то ВР нестационарен



Стационарность ВР. Замечания


- Если ряд регулярный он может не быть стационарным (но не наоборот)
- Временной ряд в ряде случаев сводится к стационарному простыми преобразованиями
- Не все методы предсказания ВР требуют сведения ВР к стационарному, но основные требуют

Примеры

• ряды a, c, d, e, f, i не стационарны, поскольку они имеют тренд;


• ряд b скорее всего стационарный, имеется выброс;

• ряды d, g, h, i не стационарны, потому что имеют сезонность.




Анализ стационарности


- Пример нестационарности линии тренда
- Пример сезонной нестационарности (в смысле дисперсии)




Stationary series



Non-Stationary series




Stationary series




Non-Stationary series

- Пример сезонной нестационарности (в смысле периода сезонности)



Stationary series




Non-Stationary series

Белый Гауссов шум

- Одним из наиболее важных случаев стационарного ВР является стационарность шума.
- Шум стационарности с независимыми выборками во времени (с автокорреляцией 0) называется шумом белого гаусса (WGN).
- Таким образом, WGN - это ряд с
 $ev = 0; var < \infty; cov(n) = std \cdot \delta(k - n),$
где $\delta(k - n) = 1$, если $k = n$, и 0 в остальных случаях.
- АКФ БГШ будет иметь некоторые ненулевые случайные значения – это эффект ограниченной выборки

Обратите внимание, что дисперсия также может быть названа мощностью шума.

Пример wgn - это когда вы выключаете антенну с телевизора и увидеть так называемый «снег»



Преобразования нестационарных временных рядов

- На самом деле почти все временные ряды нестационарны (в той или иной степени).
 - Однако, в зависимости от требований к точности в некоторых случаях мы можем сделать допущение, что ВР является стационарным для нашей задачи если он удовлетворяет каким либо нашим условиям.
 - Нестационарные ВР могут содержать ложные корреляции (тренда, сезонность, аномалии)
- Ряд можно проверить на стационарность визуально (напр. Резкий спад АКФ)
- Ряд можно проверить строго на стационарность с помощью различных статистических критериев. Наиболее популярны следующие критерии:
 - критерий KPSS (Kwiatkowski–Phillips–Schmidt–Shin): если $p\text{-value} \leq 0.05$, то отвергаем стационарность;
 - критерий Дики-Фуллера: если $p\text{-value} \leq 0.05$, то отвергаем **Н**Естационарность.

Преобразования нестационарных временных рядов

Можно ввести несколько градаций нестационарности ВР:

- Сильная стационарность
- Слабая стационарность (2 порядка)
- DS-ряд разностно-стационарный ВР
- TS-ряд – сводится к стационарному путем удаления тренда и\или сезонности
- Гетеросекдотичный ВР – может сводится к стационарному путем логарифмирования (степенного преобразования)
- Регулярный ВР – нестационарный ВР, имеющий явные паттерны поведения
- Неформализуемый ВР – паттерны поведения не явны

Преобразования нестационарных ВР

Можно ввести модель ВР стационарную по отношению к тренду или сезонности (TS модель). То есть:

$$y(t) = \text{trend}(t) + \text{seasonal}(t) + V(t)$$

где $V(t)$ – стационарная часть ВР.

Тогда можно убрать тренд и стационарность их вычитанием.

Или преобразованиями типа (DS модель):

- Дифференцирование ряда (для снятия тренда)


$$y'_t = y_t - y_{t-1}$$

- Сезонное дифференцирование (снятие сезонности)

$$\Delta_s y_t = y_t - y_{t-s}$$

s – длина сезона.

- Преобразования можно применять несколько раз.
- Обычно сначала применяют сезонное дифференцирование.




Гетероскедастичность

- Можно избавиться при помощи Бокса-Кокса или например как $y(t) = \frac{y(t+1)-y(t)}{y(t)}$





- Логарифмические преобразования
- Полиномиальные преобразования
- Преобразования Бокса-Кокса
- Комбинации с другими темами

$$y_i^{(\lambda)} = \begin{cases} \frac{y_i^\lambda - 1}{\lambda} & \text{if } \lambda \neq 0, \\ \ln(y_i) & \text{if } \lambda = 0, \end{cases}$$

- ВР после взятия обычных
- разностей




- ВР после
- логарифмирования
- и взятия разностей




Предсказания ВР с явной TS моделью

Методы предсказания в курсе




- Методы всегда выбираются от простых (слева) к самым сложным.
- Выбор метода зависит от сложности ВР (число и связи компонент, формализуемость ВР) и требований к предсказанию (горизонт, точность)
- Чем сложнее метод, тем он шире применим, но менее точен/менее устойчив/более склонен к переобучению, а также тем больше данных для обучения необходимо


Подходы к предсказанию временных рядов



Encoding (кодирование) — это процесс преобразования данных (в том числе категориальных или временных признаков) в числовую форму, удобную для обработки алгоритмами машинного обучения или статистическими методами.



Статистические методы



- Точность на коротких горизонтах предсказания
- Высокая скорость обучения и переобучения
- Высокая интерпретируемость
- Важно соответствие данных модели
- Требуется значительная предобработка данных
- Очень важна настройка модели
- Чувствительность к новизне, выбросам, пропускам и другим нерегулярностям данных
- Частое обновление модели в процессе работы

Бенчмарки предсказания временных рядов

Соревнования Макридакиса (M-Competitions) - открытые соревнования по оценке и сравнению точности различных методов прогнозирования временных рядов. en.wikipedia.org/wiki/Makridakis_Competitions

bench	Данные/задачи	Цель бенчмарка	Модели	Метрики	Победители	Выводы
M1 (1982)	1001 Univariate финансы, демография	Сравнение классических моделей	ARIMA, ETS	MAPE, RMSE	ETS, ARIMA	Baseline univariate
M2 (1993)	29 Univariate, real-time forecasting, Анализ экспертных суждений	Влияние экспертных прогнозов	Judgment vs models	RMSE, MAE	Experts ≈ ETS	Модели не хуже экспертов
M3 (2000)	3003 Univariate	универсальная модель	ARIMA, ETS, Theta	SMAPE, MAPE	ARIMA, ETS, Theta	Baseline univariate
M4 (2018)	10 000 Univariate на разных масштабах (год, месяц, и тд)	Масштабная проверка стратегий	ETS + RNN, Theta, Prophet	SMAPE, MASE	ETS + RNN, Theta	Гибрид (DL+stat) лучшие, Theta – runner up
M5 (2020)	Hierarchical, Multivariate Продажи Walmart на месяц, с категориальными признаками	Сложные огромные industrial BP	LightGBM, XGBoost, Transformer	WRMSSE, pinball loss	LightGBM+feature engineering	Продвинутый фичи - не хуже DL
M6 (2024)	Multivariate Probabilistic, Финансовые данные,	Вероятностное Прогнозирование фин. сектор	DeepAR, AutoTS, TimeGPT	CRPS, pinball loss	еще идет	еще идет

Бенчмарки предсказания временных рядов

bench	Данные/задачи	Цель	Модели	Метрики	Победители	Выводы
Температура трансформатора ETT (h/m) 2021	Multivariate (час, 15 минут и тд), 39 BP+4 экзоген парам. горизонты (96-720)	DL-прогноз сложных BP	Transformer, LSTM, N-BEATS, DLinear	MAE, MSE	PatchTST, DLinear	Трансформер работает на long horizon
Electricity Load ECL 2012	Multivariate 370 клиентов	DL-прогноз сложных BP	CNN, LSTM	MAE, MSE	CNN, LSTM	DL на больших industrial наборах
TimeRecipe (2025)	Univariate, Multivariate, Long-horizon	Эксперименты с DL моделями	NHITS, NBEATSx, PatchTST, LSTM	MAE, MSE, sMAPE	N-HITS, PatchTST, DLinear	Нет универсального победителя
ProbTS	Probabilistic, Multivariate, Univariate	Бенчмаркинг вероятностных моделей	DeepAR, TFT, Prophet, Copula	CRPS, Quantile loss	-	DL умеет делать вероятностное прогнозирование
Monash TS Forecasting	M1-M4, Tourism, Traffic, Weather, Electricity и тд	academic бенчмарк	ARIMA, Prophet, N-BEATS, D-Linear, PatchTST, TimesFM (zs), catboost	MASE, MAE, SMAPE, RMSE	-	-
gift-eval	Monash+3 бенча Разные задачи	Тест современ. Моделей	TS LLM, new RNN, Transformers	MASE, CRPS	xLSTM, Moria (zs), Chronos	LLM на очень больших данных

ОСНОВНЫЕ ВЫВОДЫ

- ARIMA, ETS, Prophet бейзлайны + LSTM (для многомерных ВР)
- Часто необходимо вероятностное прогнозирование
- Для коротких горизонтов и простых ВР стат. Методы работают отлично даже для многопеременных ВР
- Для более сложных ВР гибридные методы: стат.методы + DL
- Для средних горизонтов DL можно заменить на ML с инженерией признаков
- Для длинных горизонтов и сложных ВР – DL (трансформеры, современные RNN)
- Для больших объемов ВР и длинных горизонтов LLM
- SOTA: вероятностное прогнозирование при помощи LLM

Наивное предсказание

Наивное предсказание – это некоторая база, точностью меньше которого любой другой алгоритм не должен обладать.

Цель наивного предсказания - проверка адекватности более сложных моделей и оценка необходимости сложных моделей, а также поиск проблемных мест в процедуре предсказания

Наивные методы работают даже если ряд нарушает теорему дискретизации
не требует гипотез о модели

Пример прогноз продаж новогодних ёлок такой же как и год назад

Простое наивное предсказание $\hat{y}(T + h|T) = y(T)$.

Где h - горизонт предсказания (число шагов)

Сезонное наивное предсказание $\hat{y}(T + h|T) = y(T + h - m(k + 1))$.

Где m - период сезонности, $k = \lfloor (h - 1)/m \rfloor$


Среднее наивное предсказание/скользящее среднее $\hat{y}(T + h|T) = \frac{1}{T} \sum_{i=0}^{T-1} y(i)$.

Также может быть, например среднее сезонное предсказание,


Предсказание с дрейфом $\hat{y}(T + h|T) = y(T) + \frac{h}{T-1} \sum_{i=1}^{T-1} y(i) - y(i-1) = y(T) + h \frac{y(T) - y(1)}{T-1}$

Наивное предсказание

Google daily closing stock prices
(Jan 2015 - Jan 2016)



Forecasts for quarterly beer production



Статистические методы

Критерий	Стат. модели (ARIMA,ETS, Prophet)	ML (XGBoost, KNN, etc.)	Глубокие нейросети (LSTM, Transformer)	Генеративные модели (LLM, Dif)
Интерпретируемость	Очень высока	Умеренная	Низкая	Очень низкая
Объем данных	Минимум	Средний	Большой	Огромные данные,
Точность	При соответствии модели и данных	Зависит от выбора признаков	Средняя	Низкая
Скорость обучения/прогноза	Очень быстро	Быстро	Медленно	Очень медленно
Учет сезонности и тренда	Зависит от модели	В признаках	Хорошо	Средне
экзогенные факторы	Ограничен	Отлично	Отлично	Через контекст
Длина горизонта	Короткий	Средний	Средний-длинный	Очень длинный
Работа с шумом и выбросами, пропусками	Плохо	Хорошо (особенно ансамбли)	Средне	Хорошо
Нестационарность	Учет в модели	Хорошо	Хорошо	Возможна
Многосезонность	Ограничена	Средне	Хорошо	Хорошо
Многомерные данные	Ограниченная	Хорошо	Отлично	Отлично
Автоматизация настройки	Средняя	Высокая	Высокая	prompt engineering

Статистические методы

Метод	Тренд	Сезонность	Нестационарность	Шумы	Выбросы	Объем Данных	horizon	Настройка	Использование
Naïve	Нет, Random-walk	Одна и простая	TS-стац.	Почти нет	Почти нет	10^1 - 10^2	10	Очень быстро	Нет тренда, данных мало
STL+любой	Циклический	Одна или более (MSTL)	TS-стац.	Почти нет	Очень мало	10^1 - 10^4	20	Очень быстро	Когда проще убрать компоненты
ETS (HW)	Почти монотонный	Одна или 1-2	TS-стац.	σ -var	Очень мало	10^2 - 10^3	30	AutoETS быстр	Простая модель, 1 сезон, шумы, данных мало
TBATS	Почти монотонный	1-4	TS-стац.	Окрашенный шум, σ -var	Очень мало	10^2 - 10^4	30	Автонастройка быстро	Простая модель, шумы, несколько сезонностей
ARIMA	Полином, Random-walk	Любые, в т.ч. Нестационарные	DS-стац.	Окрашенный шум	Мало	10^2 - 10^5	100	AutoARIMA+руками - долго	Сложная DS-стац. модель, важно корреляция – по факту Baseline
Prophet	Сложный перегибы	Любые, + holidays	TS-стац.	Слабый БГШ	Могут быть	10^2 - 10^6	100+	выбор точек перегиба, ост. быстро	Длинный ВР и горизонт, бизнес-процессы

STL – разложение сезон-тренд методом локальной регрессии

БГШ – равномерно-распределенный белый гауссов шум

σ – var – гетеросекдстичный шум

Окрашенный шум – шум, имеющий корреляционную зависимость

TS-стац. – стационарность по отношению к тренду (и сезонности)

DS-стац. – стационарность к дифференцированию (usual, seasonal dif)

Экспоненциальное сглаживание


Часто требуется предсказание будущих значений достаточно простых временных рядов, состоящий преимущественно из одной трендовой и сезонной составляющих понятного вида.

Данные кажутся достаточно шумными, возникает необходимость сглаживания

Daily forecasts

HW multi damped

Forecasts of daily pageviews on the Hyndsight blog.




Forecast


HW additive forecasts

HW multiplicative forecasts

International visitors nights in Australia



Температурные показания



Классический подход к декомпозиции ВР

Рассмотрим временной с аддитивной моделью Тренд-Сезонность-остаток:

$$y_n = T_n + S_n + \varepsilon_n,$$

где T_n – это тренд, S_n – это сезонность со значением периода m (например 4 для квартала, 12 для 1 года, 7 для дней недели – если шаг 1 день), ε_n – это остаточная часть (шумы),

$n = 0, \dots, N - 1$ – набор наблюдений с заданным шагом (напр. 365 набл. С шагом 1 день – год).

В модели мы считаем, что скорость изменения тренда много меньше, чем скорость

$$\text{изменения сезонности: } \frac{1}{N} \sum_n^N |\Delta T_n| \ll \frac{1}{N} \sum_n^N |\Delta S_n|$$


Тогда если по ВР провести усредняющее окно с шириной $> m$ (в т.ч. Усреднить каждый период), то в модели останется только тренд и некоторая промоделированная ошибка ε_n

$$\hat{T}_n = \frac{1}{W} \sum_{i=0}^{W-1} y_{n-i}$$

Где $\hat{T}_n$ - оценка тренда, W – ширина окна

Такая операция будет называться W-МА (скользящее среднее)

можно делать МА над МА или ввести взвешенный МА (WMA) – выбор коэффициентов таких операций будет влиять на результат сглаживания. В том числе можно синтезировать сглаживание сезонности до определенных компонент или не менее определенных компонент (фильтрация Временного ряда)



Классический подход к декомпозиции ВР

Используя скользящее среднее проще всего разложить временной ряд на компоненты.

1 – вычисление тренда методом скользящего среднего (МА) с окном размера w (w нечетное)

$$\hat{T}_n = \frac{1}{w} \sum_{i=-(w-1)/2}^{(w-1)/2} y_{n_i} \quad \text{— центрированное скользящее среднее позволяет избежать эффекта запаздывания}$$

Если m четное - (можно заменить на $2xma$ или на другую схему)

2 – вычисление сезонности

$$s_n = y_n - \hat{T}_n$$



3 – Оценка значений одного периода сезонной составляющей с заданной сезонностью m

$$\hat{s} = (s_0, s_1, \dots, s_m) = 1/\Delta (\sum_{i=0}^{\Delta-1} s_{m \cdot i}, \sum_{i=0}^{\Delta-1} s_{m \cdot i+1}, \dots, \sum_{i=0}^{\Delta-1} s_{m \cdot i+m}),$$

где $\Delta = N \bmod m$ - целое число периодов сезона во ВР

4 – Интерполяция сезонной составляющей на весь объем выборки

5 – Вычисление остатка как $\varepsilon_n = y_n - \hat{T}_n - \hat{s}_n$







Классический подход к Detrender

Если тренд простой, то можно аппроксимировать тренд

- Полиномиальной регрессией
- Ядерной функцией (ядерное сглаживание)
- Сплайнами (Smoothing splines)
- Методом локальной регрессии (LOESS)
- Экспоненциальным сглаживанием

И т.д.

По сути – это все методы низкочастотной фильтрации BP.



Проверка на тренд

- Тренд может быть
 - детерминированным
 - Монотонный (в т.ч. с насыщением)
 - Циклическим
 - Иметь точки перегиба
 - Или может быть случайным
 - комбинированным
- Тренд важно понимать, так как он влияет на
 - стационарность (TS, DS тренды),
 - выбор модели (напр. В моделях ARIMA порядок дифференцирования это параметр)
 - Интерпретацию данных – тренд + цикличность могут маскировать сезонность и другие факторы
 - Часто тренд – это основной источник изменений во ВР, правильный учет тренда – это львиная доля высокой точности предсказания

Проверка на тренд Тесты на наличие тренда:


- **Тест Дика-Фуллера (Augmented Dickey–Fuller test, ADF)** – стохастический тренд
 - Идея: текущее изменение значений ВР связано с дрейфом или предыдущими изменениями значений ВР
 - **H0**: Ряд не стационарен (стохастический тренд).
 - **H1**: Ряд стационарен (тренда нет).
- **Тест Квятковского-Филлипса-Шмидта-Шина (KPSS)** – детерминированный тренд (кроме циклического)

Обратите внимание, H0, H1 наоборот!

 - Идея: остатки от описания ВР регрессией колеблются вокруг нуля
 - **H0**: Ряд стационарен (нет тренда или тренд колеблется вокруг нуля).
 - **H1**: Ряд не стационарен (тренд детерминирован).
- ADF + KPSS лучше вместе использовать, если есть противоречие, используйте доп. Визуальный анализ или **альтернативные тесты**:
 - гетеросекдстичность, шумы: тест Филлипса-Перрона (PP Test) - модификация ADF
 - выбросы и тд: тест Манна-Кенделла дополняет KPSS (тест на монотонный тренд)
 - В случае сложной цикличности нужно использовать время-частотный анализ или тест Бартлетта (проверка значимости сглаженных частотных компонент)

Классический подход к Deseasonalizer

- Если сезон регулярный – можно удалить его для упрощения данных
- Если известно, что сезонность переменная (например, месяцы в году), то каждый сезон можно учесть отдельно по каждому месяцу
 - Напр. потребление электроэнергии в зимой больше чем летом.
 - Выходные (weekends) могут быть промоделированы как недельная сезонность
 - Праздники могут быть промоделированы как годовая сезонность
- Если есть несколько очень разных сезонностей – их можно разрешить (напр. неделя и год).
- Если сезонность гармоническая лучше всего использовать ряды Фурье (в курсе не рассматриваем)
 - Часто описание рядами – компактное, простое, не требует целочисленной сезонности.
 - Если сезонность сложная и нестационарная лучше использовать время-частотные преобразования (в курсе не рассматриваем)



Тесты на сезонность

- Сезонность не всегда очевидна,
 - компоненты сезонности могут быть визуально скрыты другими компонентами
 - Сезонность важно не спутать с цикличностью особенно для коротких ВР
- Сезонность можно определить
 - при сравнении сегментов размером с 1 или несколько сезонов (визуально разброс, boxplot, сравнение остатков вычитания сезонностей)
 - Анализом ВР после сезонного дифференцирования
 - Путем разложения ВР на сезонные компоненты
- Сезонность видна по графикам ACF/PACF как всплески лагов на соответствующих периодах
 - Чтобы не спутать с цикличностью можно провести модифицированный тест Льюнга-Бокса. Основная идея – нормировка для лагов сезонности (напр 12,24)
 - **QS тест: вариант** тест Льюнга-Бокса только на позитивных лага
 - **Тест Кановы-Хансена (Canova-Hansen Test, CHTest):**
 - **Стабильность сезонных компонент во времени – отбор нужных компонент и анализ их изменчивости**

<https://www.hse.ru/data/2014/11/13/1311639964/%D0%9C%D0%B5%D1%82%D0%BE%D0%B4%D1%8B%20%D1%81%D0%BE%D1%86%D0%B8%D0%B0%D0%BB%D1%8C%D0%BD%D0%BE-%D1%8D%D0%BA%D0%BE%D0%BD%D0%BE%D0%BC%D0%B8%D1%87%D0%B5%D1%81%D0%BA%D0%BE%D0%B3%D0%BE%20%D0%BF%D1%80%D0%BE%D0%B3%D0%BD%D0%BE%D0%B7%D0%B8%D1%80%D0%BE%D0%B2%D0%B0%D0%BD%D0%B8%D1%8F%20%D0%B2%20%D1%82.%20%D1%82.2%20-%20%D0%A1%D0%B2%D0%B5%D1%82%D1%83%D0%BD%D1%8C%D0%BA%D0%BE%D0%B2%20-%20%D0%B1%D1%82.pdf>



<https://palatej.github.io/pages/stats/tests/seasonality/qs.html>

STL разложение

- **Проблема классических методов:**
 - Классическое разложение (например, метод скользящего среднего) предполагает **строгую периодичность** (например, 12 месяцев для годовых данных).
 - Если сезонность **изменяется во времени** (например, амплитуда или форма сезонных колебаний непостоянна), классические методы дают плохие результаты.
 - Если есть **выбросы** — это смещает результат скользящего среднего
 - Сложная форма **цикличности тренда** может быть искажена скользящим средним
- **Решение:**
 - Использование рекуррентной процедуры позволяет постепенно оптимизировать параметры разложения и сделать его устойчивым к выбросам и другим проблемам ВР
 - Процедуры локальной (непараметрической) регрессии позволяют аппроксимировать сложный тренд без его описания.
- **STL (Seasonal-Trend-Loess)** — метод сезонной и трендовой декомпозиции с помощью оценки нелинейных взаимосвязей (Loess).

STL разложение

- **STL (Seasonal-Trend-Loess)** — метод сезонной и трендовой декомпозиции с помощью оценки нелинейных взаимосвязей (Loess).



Остаток в среднем меньше, видны выбросы,

STL разложение

- Этап 1 – подготовка – линейная аппроксимация тренда, классическая оценка сезонности.
 - Выбор параметров (сезонность, окно сглаживания, окон низкочастотного сглаживания)
- Этап 2 – внутренний цикл (Разложение на тренд и сезонность)
 - Вычисление тренда $\hat{T}$ при помощи **LOESS-сглаживания** BP
 - Разбиение $y_n - \hat{T}_n$ на подциклы с заданной сезонностью, сглаживание каждого подцикла LOESS сезонным, удаление из сезонности LOESS низкочастотного и нормировка
 - Формирование оценки сезонной компоненты $\hat{S}$
 - Корректировка тренда $\hat{T}_n = y_n - \hat{S}_n$ и **LOESS-сглаживание тренда**
- **Этап 3 - Внешний цикл (итерации робастности):** Для устойчивости к выбросам (1-3 итерации).
 - Вычисление остатка $\hat{R}_n = y_n - \hat{S}_n - \hat{T}_n$
 - Устранение выбросов в остатке.
 - Если еще итерации: Восстановление нового ряда $\hat{S}_n + \hat{T}_n + \hat{R}_n$ и переход к этапу 2.

- Может также быть вариант многосезонного STL - MSTL
- Может также быть STLForecast: предсказание тренда заданной моделью и экстраполяция сезонной компоненты

Loess – взвешенная локальная регрессия с коном вида: для точки x'

$$w(x) = \begin{cases} \left(1 - \left|\frac{d(x, x')}{\max_i d(x_i, x')}\right|^3\right)^3 & |x| < 1, x_i \in D \\ 0 & |x| \geq 1 \end{cases}$$

Где d – расстояние между x и x'

другие разложения

- STL – универсальный метод разложения ВР, устойчивый к выбросам и сложным трендам. Однако,
 - **Вычислительная сложность:** Требуется больше ресурсов, чем скользящее среднее особенно для длинных ВР.
 - **Настройка параметров:** Неправильный выбор окон может исказить компоненты.
 - Для MSTL настройка еще сложнее
 - **Нестационарность:** Если тренд слишком резкий, LOESS может отставать.
 - STL может воспринимать holidays за выбросы
 - Высокочастотные шумы (зашумленность) может затмить выбросы.

- Если модель ВР уточнена, например holidays, четкая структура могут быть более точные методы, например
 - SETA (**X-13ARIMA-SEATS**) – для бизнес-процессов ВР
 - X11 для сезонной корректировки в экономических данных (глобальная экономика)